

Rapport - Probabilites et Statistiques pour le Machine Learning

Page de garde

Universite :

Module : Probabilites et Statistiques pour le Machine Learning

Etudiant :

Enseignant :

Annee universitaire :

Titre : Evaluation de probabilites, lois usuelles, regression lineaire et estimation

Introduction

Ce rapport presente la resolution de quatre problemes classiques de probabilites et de statistiques appliques au contexte du Machine Learning. Les notions utilisees sont le theoreme de Bayes, la loi binomiale, l'approximation normale, la regression lineaire et l'estimation par intervalle de confiance.

Les calculs sont verifies avec un projet Python utilisant numpy, scipy et matplotlib. Les scripts affichent les resultats dans le terminal et sauvegardent les graphiques dans le dossier figures/.

Probleme 1 - Detection de courriels frauduleux

Donnees

On note :

- F : le courriel est frauduleux ;
- D : le systeme detecte une fraude.

Les donnees du probleme sont :

- $P(F)=0.25$;
- $P(\text{not } F)=0.75$;
- $P(D|F)=0.92$;
- $P(D|\text{not } F)=0.06$.

Les probabilites complementaires sont :

$$P(\text{not } D|F)=1-P(D|F)=1-0.92=0.08$$

$$P(\text{not } D|\text{not } F)=1-P(D|\text{not } F)=1-0.06=0.94$$

Modele mathematique

Le probleme correspond a une situation de classification binaire. En Machine Learning, F represente la vraie classe, tandis que D represente la decision du modele. Les notions importantes sont le taux de detection, les faux positifs et les faux negatifs.

Calculs details

La probabilite totale qu'une alerte soit declenchee est :

$$P(D)=P(D|F)P(F)+P(D|\text{not } F)P(\text{not } F)$$

$$P(D)=0.92 \times 0.25 + 0.06 \times 0.75$$

$$P(D)=0.23+0.045=0.275$$

La probabilite qu'un courriel soit frauduleux sachant qu'une alerte est declenchee est donnee par le theoreme de Bayes :

$$P(F|D) = (P(D|F)P(F)) / (P(D))$$

$$\begin{aligned} P(F|D) &= (0.92 \times 0.25) / (0.275) \\ &= (0.23) / (0.275) \\ &= 0.836364 \end{aligned}$$

Pour le cas ou aucune alerte n'est declenchee :

$$P(\text{not } D) = 1 - P(D) = 1 - 0.275 = 0.725$$

$$P(F|\text{not } D) = (P(\text{not } D|F)P(F)) / (P(\text{not } D))$$

$$\begin{aligned} P(F|\text{not } D) &= (0.08 \times 0.25) / (0.725) \\ &= 0.027586 \end{aligned}$$

Resultats numeriques

Quantite	Valeur	Pourcentage
P(F)	0.250000	25.00 %
P(not F)	0.750000	75.00 %
P(D F)	0.920000	92.00 %
P(D not F)	0.060000	6.00 %
P(not D F)	0.080000	8.00 %
P(not D not F)	0.940000	94.00 %
P(D)	0.275000	27.50 %
P(F D)	0.836364	83.64 %
P(F not D)	0.027586	2.76 %

Resume du code Python

Le fichier probleme1.py definit les probabilites de depart, applique la formule des probabilites totales puis le theoreme de Bayes. Les resultats sont affiches sous forme decimale et en pourcentage.

Interpretation

Le taux de detection des courriels frauduleux est eleve, car $P(D|F)=92\%$. Cependant, le systeme produit aussi des faux positifs : 6% des courriels non frauduleux declenchent une alerte.

La precision de l'alerte vaut $P(F|D)=83.64\%$. Cela signifie que lorsqu'une alerte apparait, il y a environ 83.64 % de chances que le courriel soit reellement frauduleux.

Le risque de faux negatif est mesure par $P(F|\text{not } D)=2.76\%$. Meme si aucune alerte n'est declenchee, une petite probabilite de fraude subsiste. Dans un contexte de Machine Learning, ce point est important car un faux negatif peut laisser passer une attaque.

Probleme 2 - Authentification biometrique

Donnees

Un systeme biometrique reconnait correctement un utilisateur avec la probabilite :

$$p=0.95$$

On considere d'abord $n=20$ connexions independantes. La variable aleatoire X represente le nombre de connexions correctement reconnues.

Partie A - Loi binomiale

Modele mathematique

La variable X est discrete car elle compte un nombre entier de succes parmi 20 connexions. Le modele adapte est la loi binomiale :

$$X \sim B(n=20, p=0.95)$$

La loi binomiale est appropriee car :

- le nombre d'essais est fixe ;
- chaque essai a deux issues : reconnaissance correcte ou incorrecte ;
- la probabilite de succes reste constante ;
- les connexions sont supposees independantes.

Calculs details

La probabilite d'obtenir exactement 18 reconnaissances correctes est :

$$P(X=18) = C(20, 18) (0.95)^{18} (0.05)^2$$

La probabilite d'obtenir au moins 19 reconnaissances correctes est :

$$P(X \geq 19) = P(X=19) + P(X=20)$$

Pour une loi binomiale :

$$E(X) = np = 20 \times 0.95 = 19$$

$$\text{Var}(X) = np(1-p) = 20 \times 0.95 \times 0.05 = 0.95$$

$$\sigma = \sqrt{0.95} = 0.974679$$

Resultats numeriques

Quantite	Valeur
$P(X=18)$	0.188677
$P(X \geq 19)$	0.735840
$E(X)$	19.0000
$\text{Var}(X)$	0.9500
σ	0.974679

Partie B - Simulation Python

Methode

Le fichier `probleme2.py` utilise `numpy.random.default_rng` avec la graine fixe 2026. Il simule 1000 expériences de la variable X , puis calcule la moyenne, la variance, l'écart-type et les probabilités empiriques.

Resultats empiriques


Quantite	Valeur theorique	Valeur empirique
Moyenne	19.0000	18.9290
Variance	0.9500	0.9860
Ecart-type	0.974679	0.992955
$P(X=18)$	0.188677	0.209000
$P(X \geq 19)$	0.735840	0.709000

Les valeurs empiriques sont proches des valeurs theoriques. Les écarts sont normaux car la simulation utilise un nombre fini d'expériences.

Figure

L'histogramme des simulations est sauvegarde dans :

`figures/probleme2_histogramme_binomiale.png`



Cette figure montre que les valeurs observees sont concentrees autour de 19 et 20, ce qui est coherent avec une probabilite de reconnaissance elevee.

Partie C - Approximation normale

On considere maintenant :

$$X \sim B(n=200, p=0.95)$$

Pour une grande valeur de n , on peut approximer X par une loi normale :

$$Y \sim N(\mu, \sigma^2)$$

avec :

$$\mu=np=200 \times 0.95=190$$

$$\sigma^2=np(1-p)=200 \times 0.95 \times 0.05=9.5$$

$$\sigma=\sqrt{9.5}=3.082207$$

Calculs avec correction de continuité

Pour $P(X \geq 185)$, on utilise :

$$P(X \geq 185) \approx P(Y \geq 184.5)$$

Pour $P(180 \leq X \leq 195)$, on utilise :

$$P(180 \leq X \leq 195) \approx P(179.5 \leq Y \leq 195.5)$$

Comparaison numerique


Probabilite	Exacte binomiale	Approximation normale
$P(X \geq 185)$	0.955644	0.962824
$P(180 \leq X \leq 195)$	0.972393	0.962495

L'approximation normale est assez proche des probabilites exactes. Les differences restent faibles, ce qui montre que l'approximation est raisonnable pour $n=200$, meme si $p=0.95$ est proche de 1.

Figure

La comparaison entre la loi binomiale et l'approximation normale est sauvegardee dans :

figures/probleme2_approximation_normale.png



Interpretation Machine Learning

Le systeme semble fiable et stable : avec 200 connexions, le nombre moyen de reconnaissances correctes est de 190. La probabilite d'obtenir au moins 185 reconnaissances correctes est superieure a 95 %. Dans une application de Machine Learning, cela indique une performance globale elevee, mais il faut aussi surveiller les erreurs d'authentification car elles peuvent avoir des consequences importantes pour l'utilisateur.

Probleme 3 - Regression lineaire

Donnees

Les donnees representent la population mondiale, en milliards, entre 1950 et 2020 :

Annee	Population
1950	2.54
1955	2.77
1960	3.03
1965	3.34
1970	3.70
1975	4.08
1980	4.46
1985	4.87
1990	5.33
1995	5.74
2000	6.14
2005	6.54
2010	6.96
2015	7.38
2020	7.80

Modele mathematique

On cherche une droite de regression lineaire :

$$\hat{y} = ax + b$$

ou :

- x est l'annee ;
- y est la population mondiale observee ;
- a est la pente ;
- b est l'ordonnee a l'origine.

Calculs details

Le point moyen est :

$$\bar{x} = (1/n) \sum_{i=1}^n x_i = 1985$$

$$\bar{y} = (1/n) \sum_{i=1}^n y_i = 4.9787$$

Le coefficient de corrélation linéaire calculé avec `np.corrcoef` est :

$$r=0.99791698$$

Cette valeur est très proche de 1, ce qui indique une très forte corrélation linéaire positive entre l'année et la population mondiale observée.

La droite obtenue avec `np.polyfit(x, y, 1)` est :

$$a=0.077457142857$$

$$b=-148.773761904762$$

Donc :

$$\hat{y} = 0.077457x - 148.773762$$

La prédiction pour 2050 est :

$$\hat{y}(2050)=0.077457 \times 2050 - 148.773762$$

$$\hat{y}(2050)=10.013381$$

La population prédite pour 2050 est donc environ 10.013 milliards d'habitants.


Resume du code Python

Le fichier `probleme3.py` crée les vecteurs `x` et `y`, calcule le point moyen, le coefficient de corrélation, la droite de régression et la prédiction pour 2050. Il produit aussi un graphique contenant les observations, la droite de régression, le point moyen et le point prédit pour 2050.

Figure

Le graphique est sauvegardé dans :

`figures/probleme3_regression_lineaire.png`



Interpretation Machine Learning

La pente a indique que, selon le modèle linéaire, la population augmente en moyenne d'environ 0.077457 milliard par an, soit environ 77.46 millions de personnes par an.

L'ordonnée à l'origine b a une interprétation directe limitée, car l'année 0 est très loin de l'intervalle observé. Elle sert surtout à positionner la droite mathématiquement.

En Machine Learning, les paramètres a et b sont choisis pour minimiser une fonction de perte, souvent l'erreur quadratique moyenne :

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Cette minimisation peut se faire par la méthode analytique des moindres carrés ou par descente de gradient. Dans la descente de gradient, les paramètres sont mis à jour itérativement afin de réduire l'erreur.

La prédiction obtenue pour 2050 doit être interprétée avec prudence. Elle repose sur une extrapolation linéaire hors de l'intervalle 1950-2020. Or, l'évolution démographique n'est pas parfaitement linéaire : la fécondité, la mortalité, les migrations, les politiques publiques et les crises peuvent modifier la trajectoire.

Probleme 4 - Estimation et intervalle de confiance

Donnees

Les longueurs d'abeilles sont données par classes :

Classe (mm)	Centre	Effectif
[3.5,4.5[	4	1
[4.5,5.5[	5	2

Classe (mm)	Centre	Effectif
[5.5,6.5[	6	23
[6.5,7.5[	7	46
[7.5,8.5[	8	24
[8.5,9.5[	9	3
[9.5,10.5[	10	1

Le total est :

$$n=100$$

Reconstruction de l'échantillon

Comme les données sont groupées, on reconstruit un échantillon approximatif en répétant chaque centre de classe selon son effectif :

- une valeur égale à 4 ;
- deux valeurs égales à 5 ;
- vingt-trois valeurs égales à 6 ;
- quarante-six valeurs égales à 7 ;
- vingt-quatre valeurs égales à 8 ;
- trois valeurs égales à 9 ;
- une valeur égale à 10.

Cette reconstruction est approximative car on remplace toutes les valeurs d'une classe par son centre.

Calculs détaillés

La moyenne empirique est :

$$m_e = (\sum n_i c_i) / (n)$$

$$m_e = (1 \times 4 + 2 \times 5 + 23 \times 6 + 46 \times 7 + 24 \times 8 + 3 \times 9 + 1 \times 10) / (100)$$

$$m_e = (703) / (100) = 7.03$$

La variance empirique avec dénominateur n est :

$$V_e = (\sum n_i (c_i - m_e)^2) / (n)$$

$$V_e = 0.849100$$

L'écart-type empirique est :

$$\sigma_e = \sqrt{V_e} = 0.921466$$

L'estimateur de la moyenne de la population est la moyenne empirique :

$$\hat{\mu} = m_e$$

Comme la variance de la population est inconnue, l'estimateur de la variance utilise le dénominateur n-1 :

$$s^2 = (\sum (x_i - \bar{x})^2) / (n-1)$$

$$s^2 = 0.857677$$

$$s = 0.926108$$

Intervalle de confiance a 95 %

La variance de la population etant inconnue, on utilise la loi de Student :

$$\bar{x} \pm t_{\{0.975, n-1\}}(s) / (\sqrt{n})$$

Avec $n=100$, $n-1=99$ et :

$$t_{\{0.975, 99\}} = 1.984217$$

La marge d'erreur est :

$$1.984217 \times \frac{0.926108}{\sqrt{100}} = 0.183760$$

Donc :

$$IC_{\{95\% \}} = [7.03 - 0.183760, ; 7.03 + 0.183760]$$

$$IC_{\{95\% \}} = [6.846240, ; 7.213760]$$

L'amplitude de l'intervalle est :

$$7.213760 - 6.846240 = 0.367520$$

Taille minimale pour une amplitude inferieure a 0.1 mm

On utilise l'approximation normale :

$$2z_{\{0.975\}}(s) / (\sqrt{n}) < 0.1$$

Donc :

$$n > \left(\frac{2z_{\{0.975\}}(s)}{0.1} \right)^2$$

Avec $z_{\{0.975\}} = 1.959964$ et $s = 0.926108$:

$$n > \left(\frac{2 \times 1.959964 \times 0.926108}{0.1} \right)^2$$

$$n > 1317.85$$

On arrondit au superieur :

$$n_{\{min\}} = 1318$$

Ce calcul utilise l'ecart-type corrige de l'echantillon comme estimation de l'ecart-type de la population.

Resultats numeriques

Quantite	Valeur
n	100
Moyenne empirique m_e	7.030000 mm
Variance empirique V_e	0.849100
Ecart-type empirique	0.921466 mm
Variance corrigeée s^2	0.857677
Ecart-type corrigé s	0.926108 mm
$t_{\{0.975,99\}}$	1.984217
IC 95 %	[6.846240 ; 7.213760] mm
Amplitude	0.367520 mm
Taille minimale pour amplitude < 0.1 mm	1318


Resume du code Python

Le fichier `probleme4.py` cree les tableaux centres et effectifs, reconstruit l'echantillon avec `np.repeat`, calcule les estimateurs et construit l'intervalle de confiance avec `scipy.stats.t`. Il calcule aussi la taille minimale necessaire pour obtenir un intervalle plus precis.

Figure

L'histogramme est sauvegarde dans :

`figures/probleme4_histogramme_abeilles.png`



Interpretation statistique

La longueur moyenne estimée est de 7.03 mm. La plupart des observations se concentrent autour des classes centrées en 6, 7 et 8 mm, ce qui montre une tendance centrale nette.

La variabilite est moderee : l'ecart-type corrige est environ 0.926 mm. L'intervalle de confiance a 95 % signifie que, selon le modele statistique utilise, une methode identique de construction d'intervalles contiendrait la vraie moyenne de la population dans environ 95 % des echantillons de meme type.

L'amplitude actuelle, environ 0.368 mm, est superieure a 0.1 mm. Pour obtenir une estimation plus precise, il faudrait augmenter fortement la taille de l'echantillon, jusqu'a au moins 1318 abeilles selon l'approximation normale.

Conclusion

Les quatre problemes montrent comment les probabilites et les statistiques servent a analyser des situations typiques du Machine Learning.

Dans le premier probleme, le theoreme de Bayes permet d'evaluer la precision d'un detecteur de fraude et le risque de faux negatif. Dans le deuxieme probleme, la loi binomiale modelise naturellement le nombre de reconnaissances correctes d'un systeme biometrique, tandis que la simulation et l'approximation normale permettent de verifier et d'etendre l'analyse. Dans le troisieme probleme, la regression lineaire illustre la construction d'un modele predictif simple. Enfin, le quatrieme probleme montre comment estimer une moyenne de population et comment la taille d'echantillon influence la precision d'un intervalle de confiance.

Le projet Python associe a ce rapport permet de reproduire tous les resultats numeriques et de regenerer les figures automatiquement.